

Detección de melanoma - Comparación de distintos modelos basados en redes neuronales artificiales



Ricardo Hernández, Pablo Meza

Departamento de Ingeniería Industrial, Universidad de Concepción, Concepción, Chile
rihernandez2016@udec.cl, pmeza2016@udec.cl


1. Introducción

El melanoma es la transformación maligna del melanocito. Este tumor tiene gran capacidad de invasión en la zona y frecuentemente produce la muerte en las personas que padecen esta malformación. Se estima que cerca del 80% de las personas que padecen de un melanoma o cáncer a la piel no se recuperan y terminan perdiendo la vida a causa de ello. En este estudio se plantean distintos modelos de clasificación basados en redes neuronales del tipo multilayer perceptron, convolucionales y arquitecturas complejas de redes neuronales, para clasificar imágenes de naevus y melanomas como herramienta para la detección de melanomas.




2. Set de datos

El set de datos que se utilizará consta de 170 imágenes macroscópicas RGB (70 casos de melanoma y 100 nevus) extraídas del archivo de imágenes digitales del Departamento de Dermatología del Centro Médico Universitario de Groningen (UMCG).



3. Data Augmentation

Dada la poca cantidad de imágenes se aplicó la técnica "Data Augmentation" que tomaba cada imagen y le aplicaba distintos tipos de transformaciones aleatorias como acercamiento, rotación, flip vertical, flip horizontal, desplazamiento horizontal y vertical para generar nuevas imágenes como se aprecia a continuación. Esto permitió incrementar las imágenes, generando 4720 imágenes en el set de entrenamiento y 2080 imágenes en el set de validación.



4. Modelos

Se realizaron cinco modelos de redes neuronales, estos son un multilayer perceptrón, dos basados en redes neuronales convolucionales y dos en arquitecturas complejas de redes neuronales.

- 1) El primer modelo, es un modelo multilayer perceptrón (MLP), cuya arquitectura consiste en una capa de entrada de tipo Flatten unida a tres capas densas, con dos de ellas regularizadas con L1 y L2. Adicionalmente a cada capas densa se le aplica regularización mediante Dropout. Finalmente, se termina la estructura con una capa densa compuesta solamente por una neurona y activación del tipo "sigmoid".
- 2) El segundo modelo (CNN1) cuenta con una capa de entrada seguida de 5 capas convolucionales, a las cuales cada una de ellas tiene a continuación una capa Maxpooling. Posteriormente le sigue una capa Flatten y una capa densa para la salida con una neurona y activación "sigmoid".
- 3) Modelo híbrido (CNN2) compuesto de la misma forma que el modelo anterior, sin embargo, cuenta con una capa densa entre la capa Flatten y la capa de salida.
- 4) El cuarto modelo (CM1) es un modelo no secuencial que utiliza 2 secciones de extracción de características, las cuales utilizan capas convolucionales y capas maxpooling. En una sección se utilizan filtros de 2x2 y en la otra sección filtros de 5x5. Las dos secciones finalizan con una capa Flatten que se concatenan para luego pasar por capas densas hasta la capa de densa de salida con una neurona y activación "sigmoid".
- 5) El quinto modelo (CM2) similar al CM1, diferenciándose principalmente en que las dos secciones de extracción de características utilizan filtros de 2x2, y la entrada para uno de ellas es el input de la red pero con una rotación fija.

5. Resultados

Se puede observar según los desempeños de los distintos modelos mostrados, que el modelo CNN1 arrojó mejores resultados en todas las métricas, lo que implica que a la hora de predecir los datos de entrenamiento y datos jamás visto en el entrenamiento, el modelo CNN1 es más confiable y preciso.

Metrics	MLP	CNN1	CNN2	CM1	CM2
Train Accuracy (%)	70.55	96.63	95.55	83.81	81.65
Val. Accuracy (%)	78.61	84.86	82.21	81.01	80.82
Val. TP (%)	70.0	79.0	57.0	59.0	75.0
Val. FP (%)	19.0	14.0	11.0	13.0	17.0
Val. TN (%)	81.0	86.0	89.0	87.0	82.0
Val. FN (%)	30.0	21.0	42.0	41.0	25.0

7. Referencias

1)Julia K. Winkler, Katharina Sies, Christine Fink, Ferdinand Toberer, Alexander Enk, Teresa Deinlein, Rainer Hofmann-Wellenhof, Luc Thomas, Aimilios Lallas, Andreas Blum, Wilhelm Stolz, Mohamed S. Abass, Tobias Fuchs, Albert Rosenberger, Holger A. Haenssle. (2020). Melanoma recognition by a deep learning convolutional neural networkd-Performance in different melanoma subtypes and localisations. ELSEVIER.

6. Conclusiones

Se concluye principalmente lo siguiente:

1. Estructuras de redes convolucionales complejas entregan mejores resultado y suelen ser más confiables para estos problemas
2. Es posible aumentar el la cantidad de datos en base a los existentes generando beneficios positivos para los modelos y entrenamientos.
3. Es posible ayudar a combatir los melanomas a través de la detección con modelos de Machine Learning, sin embargo, se recomienda crear modelos más complejos como los vistos en las referencias para trabajar de forma segura.